

家庭电力消耗多变量时间序列预测

2026 年专硕机器学习课程项目实验报告

学号： 20255227075 姓名： 刘通

代码仓库： <https://github.com/Liuziming0/ML.git>

作者贡献说明：单人完成。研究领域：自然语言处理。

AI 使用声明：本报告撰写过程中使用了 DeepSeek 与 Cursor AI 辅助组织语言与润色、表格设计与格式规范。

1 问题介绍

随着智能家居与物联网技术的发展，家庭电力消耗的监测与预测在节能减排、降低用电成本以及智能电网调度中具有重要价值。家庭用电受季节变化、节假日、成员行为模式、设备类型及气象条件等多因素影响，呈现明显的非线性与周期性，准确预测具有较大挑战性和现实意义。

本实验基于 UCI 公开的 Individual Household Electric Power Consumption 数据集 [1]。该数据来自法国 Sceaux 一户家庭，采样粒度为分钟，时间跨度为 2006 年 12 月至 2010 年 11 月。实验根据最近 90 天的多变量用电与气象信息，预测未来日级总有功功率，对应字段为 `global_active_power`。短期任务预测未来 90 天，长期任务预测未来 365 天；两种任务分别训练独立模型，参数不共用。输入为过去 90 天的多变量序列。评价指标为均方误差 MSE 与平均绝对误差 MAE；每种配置重复 5 次实验，报告均值与标准差。

本实验采用 Direct Multi-step Forecasting 策略，即直接多步预测：模型在一次前向传播中输出完整的 90 或 365 日预测序列，而非逐步自回归滚动。该做法与短期、长期分别训练的要求一致，推理效率较高。

电力数据来自 UCI 仓库 [1]，气象数据来自法国 Météo-France 月度气候数据集 [2]。课程未提供官方训练集与测试集划分文件，本实验按时间顺序划分：训练集为 2006-12-16 至 2008-12-31，共 747 天；测试集为 2009-01-01 至 2010-11-26，共 695 天。测试集长度满足长期预测所需的最少 455 天窗口。

原始数据为分钟级记录，缺失值以“?”标记，约占 1.25%。按作业要求，全局有功功率、全局无功功率与三路分表能耗均按天求和；电压与全局电流强度按天求平均；气象变量 `RR`、`NBJRR1`、`NBJRR5`、`NBJRR10`、`NBJBROU` 为月度数据，广播至该月各天。其中第三路分表对应气候控制系统。分钟级衍生特征 `sub_metering_remainder` 按公式

$$\text{sub_metering_remainder} = \frac{\text{global_active_power} \times 1000}{60} - (\text{sub_1} + \text{sub_2} + \text{sub_3}) \quad (1)$$

计算后按日求和。预处理阶段由日期字段生成星期、月份、年内序号与是否周末等日历特征，并与其他变量一并纳入模型输入。

气象站选用 Hauts-de-Seine 省 FONTENAY-CEN 站，编号 92032001。该站距 Sceaux 最近，且在 2006–2010 年有完整记录。`RR` 原始值为毫米的十分之一，已除以 10 换算；`NBJBROU` 在该站缺失，统一填 0。标准化在训练集上拟合，测试集仅做变换，避免信息泄漏。

样本采用步长为 1 的滑动窗口构造 [7, 8, 9]。每个样本的输入为 $\mathbf{X} \in \mathbb{R}^{90 \times F}$ ，输出为 $\mathbf{y} \in \mathbb{R}^H$ ，其中 H 取 90 或 365，特征维数 $F = 17$ 。训练集含短期样本 568 个、长期 293 个；测试集含短期 516 个、长期 241 个。

2 模型

本实验实现 LSTM、Transformer 与 CNN-Transformer 三种模型。短期任务为 90 天输入、90 天输出；长期任务为 90 天输入、365 天输出。两类任务分别独立训练，基于 PyTorch 框架实现。

2.1 LSTM 模型

LSTM 模型以两层、隐层维度 128 的 LSTM 编码过去 90 天序列，取最后时刻隐状态，经两层全连接网络映射到 H 步输出。给定输入 $\mathbf{x} \in \mathbb{R}^{90 \times F}$ ，有 $\mathbf{h}_T = \text{LSTM}(\mathbf{x})$ ， $\hat{\mathbf{y}} = \text{MLP}(\mathbf{h}_T)$ ，损失为 $\mathcal{L} = \text{MSE}(\hat{\mathbf{y}}, \mathbf{y})$ 。LSTM 擅长建模序列依赖 [3]，作为经典基线。

2.2 Transformer 模型

Transformer 模型将输入线性投影至 $d_{\text{model}} = 64$ ，叠加正弦位置编码，经两层、四头注意力的 Encoder，在时间维均值池化后，再经 MLP 输出 H 步。自注意力可建模长期依赖 [4]。Zeng 等 [5] 指出标准 Transformer 在时序任务上对局部连续模式建模不足，这也是设计改进模型的出发点。

2.3 CNN-Transformer 改进模型

改进模型在 Transformer 前串联三层 Conv1D，卷积核依次为 3、5、7，再经位置编码、Encoder 与 MLP 一次性输出 H 步。卷积与注意力均为常见组件，但具体组合与超参数针对本任务自行确定，并未复现某一已有网络。

设计过程如下。基线 Transformer 在本数据上短期表现尚可，但家庭用电存在明显日周期与周周期，纯注意力对短周期归纳偏置较弱 [5]，因此在编码前增加局部特征提取。输入为 90 天日粒度序列，自行选取 kernel 为 3、5、7 的三层卷积，分别约对应 3 天、1 周与 2 周感受野，由细到粗抽象局部模式。Kleeberg 等 [6] 在同一 UCI 数据集上采用 CNN-LSTM 并融合气象数据；本模型改用 CNN-Transformer，并采用 Direct 多步输出，卷积核与层数均不同。相对 LSTM，本模型以注意力替代逐步递归并加入卷积前端；相对 Transformer，在编码前显式提取局部周期特征。

2.4 训练设置

优化器为 Adam，学习率 10^{-3} ，损失为 MSE。短期 batch size 为 32，长期为 16；最大 epoch 80，早停 patience 12；随机种子取 42、123、456、789、2026。在训练集滑动窗口样本中按时间顺序取末尾 10% 作验证集，用于早停。最终 MSE 与 MAE 在 2009 年后的独立测试集上计算，测试时段与训练时段不重叠。

3 结果与分析

3.1 定量结果

表 1 汇总三种模型在测试集上的结果。指标在反归一化后的原始尺度上计算，各配置重复 5 次实验，表中为均值与标准差。

表 1: 各模型测试集 MSE 与 MAE

模型	预测长度	MSE	MAE
LSTM	短期 90 天	297527.66 $\pm$ 8633.30	415.48 $\pm$ 8.05
LSTM	长期 365 天	222779.94 $\pm$ 11713.97	353.23 $\pm$ 10.95
Transformer	短期 90 天	262198.22 $\pm$ 25517.02	389.47 $\pm$ 20.57
Transformer	长期 365 天	290486.83 $\pm$ 26657.28	412.45 $\pm$ 25.34
CNN-Transformer	短期 90 天	263430.64 $\pm$ 69678.44	385.40 $\pm$ 56.65
CNN-Transformer	长期 365 天	226228.67 $\pm$ 24559.67	355.72 $\pm$ 23.84

3.2 结果讨论

长期预测任务上，LSTM 的 MSE 与 MAE 最低，且五次实验的标准差较小，MAE 标准差约为 10.95，训练较稳定。这可能因为 LSTM 的递归结构更适合平滑、缓慢的年度趋势，而一次性输出 365 步对 Transformer 类模型的容量与优化要求更高。短期预测上，Transformer 的 MSE 最低，为 262198，三种模型差距不大，说明在日尺度与周尺度规律下各架构均可学习。CNN-Transformer 短期 MSE 标准差为 69678，高于 LSTM 的 8633 与 Transformer 的 25517，对初始化较敏感；长期任务方差有所降低，但仍高于 LSTM。总体而言，LSTM 最稳定，Transformer 居中，CNN-Transformer 短期波动最大。

3.3 预测曲线

图 1 与图 2 分别给出短期与长期预测的三模型对比，图 3 为单模型示例。




图 1: 短期 90 天三种模型预测曲线与真实值对比






图 2: 长期 365 天三种模型预测曲线与真实值对比



(a) LSTM 短期预测, seed 为 42



(b) CNN-Transformer 长期预测, seed 为 42

图 3: 单模型预测示例

从曲线可见, 模型能捕捉总体趋势与部分周期波动, 但在用电峰值与突变日上仍有偏差。长期预测后半段误差有所增大, 这是 Direct 策略的常见现象。长期任务中 LSTM 曲线整体更贴近真实值; CNN-Transformer 在部分区段对局部波动响应更明显。

4 讨论

本实验采用 Direct 策略, 一次性输出 90 或 365 步预测, 推理速度快, 且与短期、长期分别训练的要求一致。其不足在于输出维数较高, 365 步预测时对模型容量要求更大。此外, 当前输入仅含过去 90 天的日历特征, 预测未来各天时模型并不知道该日的星期与月份; 而这些信息在实际部署中可以预先计算, 后续可为每个预测步构造未来日历特征加以改进。

第三路分表能耗已按日求和。气象站因 Sceaux 本站停测而选用邻近 Fontenay 站; **NBJBROU** 缺失处填 0。验证集为训练窗口末尾 10%, 仅用于早停; 测试集为 2009 年后独立时段, 与训练无重叠。

CNN-Transformer 在长期任务上接近 LSTM, MSE 分别为 226229 与 222780; 短期 MAE 略优于 LSTM, 分别为 385.40 与 415.48, 但未全面超越基线, 且不同 seed 间方差较大。文献 [5, 6] 用于说明问题背景与数据集参照, 模型结构为自行设计。后续可引入未来日历特征, 尝试 Encoder-Decoder 结构, 并对 CNN-Transformer 增加学习率 warmup 以提升稳定性。

完整可运行代码已托管于 GitHub, 链接见文首。克隆仓库后安装依赖, 将 UCI 原始数据放入数据目录, 依次运行天气下载、预处理与实验脚本即可复现。

参考文献

- [1] UCI Machine Learning Repository. *Individual Household Electric Power Consumption*. <https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption>

- [2] data.gouv.fr. *Données climatologiques de base - mensuelles*. <https://www.data.gouv.fr/fr/datasets/donnees-climatologiques-de-base-mensuelles>
- [3] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- [4] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30.
- [5] Zeng, A., Chen, M., Zhang, L., et al. (2023). Are Transformers Effective for Time Series Forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121–11128.
- [6] Kleeberg, J., et al. (2021). Energy Consumption Patterns and Load Forecasting with Profiled CNN-LSTM Networks. *Processes*, 9(11), 1870.
- [7] 滑动窗口样本构造. https://blog.csdn.net/qq_47885795/article/details/143462299
- [8] 时间序列窗口划分. https://blog.csdn.net/weixin_39653948/article/details/105431099
- [9] 时间序列预测样本构造. <https://datac.blog.csdn.net/article/details/105928752>